

Pestaña 1: Olink / UK Biobank

El estudio en una frase

Cogieron 44.306 personas completamente sanas en Reino Unido, les sacaron sangre, midieron casi 3.000 proteínas, y las siguieron durante 13 años para ver quién desarrollaba FPI.

Este es **el único estudio verdaderamente predictivo** de todos los que hemos visto. Los demás miran personas que ya tienen algo (ILA, familiares de enfermos). Este mira personas sin nada y pregunta: ¿qué hay en tu sangre hoy que anuncia que en 10 años tendrás FPI?

Los números del recuadro superior

44.306 participantes. Es una muestra enorme. Cuanto más grande, más fiable es el resultado.

13.6 años de seguimiento. Midieron las proteínas al inicio y esperaron más de 13 años. Eso es clave para tu objetivo: te dice que estas proteínas estaban elevadas mucho antes del diagnóstico, no justo cuando ya había síntomas.

641 casos de FPI. De los 44.306, solo 641 desarrollaron FPI. Es una enfermedad rara, por eso necesitaban una muestra tan grande para tener suficientes casos.

2.920 proteínas analizadas, 464 asociadas a FPI. Midieron casi 3.000 proteínas en cada persona y encontraron que 464 de ellas tienen alguna relación con el riesgo de FPI. Eso es mucho, pero tiene sentido: la FPI es una enfermedad compleja que afecta a muchos procesos biológicos.

Por qué usaron Olink y no SomaScan

Olink mide las proteínas usando anticuerpos, igual que funcionan muchos análisis de sangre clínicos. Es más específico, con menos señal falsa, pero mide menos proteínas que SomaScan. El UK Biobank eligió Olink precisamente porque buscaban fiabilidad para un estudio tan grande y largo. Si los resultados hubieran sido ruidosos con tantas personas y tantos años, habrían sido inútiles.

Las proteínas de riesgo: por qué estas y no otras

De las 464 proteínas asociadas a FPI, el estudio muestra las 5 con señal más fuerte. Te explico por qué cada una es interesante.

LAMP3 — HR 2.83

Es la que tiene el HR más alto de todas. Las personas con LAMP3 alta en sangre desarrollaron FPI casi 3 veces más que las que la tenían baja, con 13 años de antelación.

Lo más relevante es que nadie la había relacionado con FPI antes. Es una proteína que vive en los lisosomas, que son como los contenedores de basura de la célula. Cuando los lisosomas no funcionan bien, la célula acumula daño. En FPI parece que LAMP3 sube cuando hay estrés crónico en las células del epitelio pulmonar, mucho antes de que ese estrés sea visible en el TAC. Por eso es tan interesante para predicción precoz: señala un proceso que está ocurriendo silenciosamente.

La razón por la que la destacamos sobre otras proteínas con HR similar es que su señal tiene un intervalo de confianza muy estrecho (2.58–3.11), lo que significa que el resultado es muy preciso, no hay mucha incertidumbre. Y es nueva, lo que la convierte en una hipótesis de investigación con mucho recorrido.

WFDC2 — HR 2.06

Tiene un HR menor que LAMP3 pero es la proteína más importante del conjunto por una razón: aparece en todos los estudios, en todas las plataformas y en todos los subgrupos de población. Eso es lo que en ciencia se llama replicación, y es la mejor garantía de que no es un resultado casual.

WFDC2 (también conocida como HE4) es una proteína que produce el epitelio del pulmón. Su función biológica es inhibir ciertas enzimas que degradan el colágeno. Cuando WFDC2 sube, esas enzimas se inhiben, el colágeno se acumula, y ese acúmulo es exactamente el inicio de la fibrosis. Así que no es solo un marcador pasivo, tiene un mecanismo que lo conecta directamente con la fibrosis.

La razón por la que la priorizaría sobre las demás para predicción longitudinal es esa combinación: efecto grande, mecanismo claro, y reproducible en múltiples contextos independientes.

GDF15 — HR 1.92

GDF15 es una citocina de la familia del TGF- β , que es precisamente la señal central de la fibrosis. Cuando las células están bajo estrés, envejecimiento o daño, liberan GDF15. Por eso sube en muchas condiciones distintas: FPI, enfermedades cardíacas, cáncer, envejecimiento normal.

El problema de GDF15 es justamente ese: es muy sensible pero poco específica. Su HR de 1.92 es real y significativo, pero si alguien tiene GDF15 alta puede ser por muchas razones que no son FPI.

Lo que la hace valiosa en este contexto es que cuando se combina con otras proteínas como WFDC2 o CDCP1, la especificidad mejora mucho. Sola es un marcador de daño genérico. En un panel es un componente útil.

SPINT1 — HR 1.60

Es un inhibidor del factor de crecimiento hepático (HGF). El HGF normalmente protege contra la fibrosis porque promueve que los fibroblastos mueran cuando ya no son necesarios. SPINT1 bloquea ese efecto protector, así que cuando SPINT1 sube, los fibroblastos sobreviven más de lo que deberían y la fibrosis avanza.

Es menos conocida que las anteriores pero tiene un mecanismo muy concreto y directamente relacionado con la FPI. Y su intervalo de confianza es excepcionalmente estrecho (1.54–1.66), lo que indica una señal muy consistente entre los 44.000 participantes.

CEACAM6 — HR 1.45

Es la más modesta de las cinco en cuanto a efecto, pero tiene algo especial: nadie la había vinculado antes a la FPI. Es completamente nueva como biomarcador de esta enfermedad. Su mecanismo en la fibrosis no está aclarado todavía, lo que la convierte en una hipótesis abierta para investigación.

La razón por la que aparece aquí a pesar de tener el HR más bajo es que su p-valor es uno de los más bajos de todo el estudio (2.62E-118), lo que significa que la señal es extremadamente robusta estadísticamente. Es pequeña en efecto pero muy fiable.

Las proteínas protectoras: por qué son igual de importantes

EGFR — HR 0.67

Cuando EGFR está alta en sangre, el riesgo de FPI es un 33% menor. EGFR es un receptor de membrana que regula la supervivencia y reparación de las células epiteliales. Cuando funciona bien, el epitelio del pulmón se repara correctamente tras un daño. Cuando EGFR baja, esa capacidad de reparación falla y el pulmón responde con fibrosis en lugar de regeneración.

Lo destacamos sobre las demás protectoras porque su señal aparece también en el estudio de SomaScan/QIA con un efecto de -4.35, el más grande de todos los negativos. Dos plataformas completamente distintas dicen lo mismo: EGFR bajo en sangre es señal de riesgo. Eso es muy difícil de ignorar.

TTR e IGFBP3

TTR (transtiretina) está baja en pacientes con FPI establecida y se asocia a peor pronóstico. Es una proteína hepática y su descenso refleja posiblemente un estado de malnutrición o sarcopenia que acompaña a la enfermedad. Útil como marcador de riesgo combinado.

IGFBP3 solo es significativo en hombres mayores de 60 años con historial de tabaco. En otros subgrupos no funciona. Por eso, aunque su HR es 0.78, su aplicabilidad práctica es más limitada que la de EGFR.

El modelo predictivo: por qué el salto más honesto es de 0.779 a 0.884

Ya te lo expliqué antes, pero en contexto: con solo saber la edad, el sexo, si fuma y su IMC, predices correctamente el 77.9% de las veces quién tiene más riesgo. Añadir las proteínas te lleva al 88.4%. Ese salto de casi 11 puntos es lo que justifica todo el esfuerzo de medir proteínas.

El 0.986 del modelo con 256 proteínas individuales es probablemente exagerado por razones técnicas que ya te expliqué. Pero incluso si el número real fuera 0.92 o 0.93, seguiría siendo un salto enorme.

La conclusión práctica de esta pestaña para tu objetivo

Si quieres predecir FPI en personas que todavía no la tienen, el Olink del UK Biobank te da las proteínas más relevantes: **WFDC2 primero** por consistencia, **LAMP3 segundo** por efecto y novedad, **GDF15 tercero** como complemento sistémico, y **EGFR como protectora** que confirmar en tu cohorte.

Estas cuatro proteínas, medidas en sangre de personas sanas, tienen señal demostrada 13 años antes del diagnóstico.

Pestaña 2: SomaScan / ILA familiar

El estudio en una frase

Cogieron 237 familiares de primer grado de pacientes con FPI, les midieron casi 8.000 proteínas en sangre con SomaScan, y les hicieron un TAC para ver quién ya tenía ILA (anomalías precoces en el pulmón) y quién no.

La diferencia fundamental con el estudio anterior

Esto es lo primero que tienes que entender porque cambia cómo interpretar todo lo demás.

El UK Biobank cogió personas de la población general y las siguió 13 años. Aquí no hay seguimiento. Es una foto fija: miden proteínas y TAC el mismo día, y comparan los que ya tienen ILA con los que no.

Esto significa que el OR no te dice "esta proteína predice quién desarrollará FPI en el futuro". Te dice "entre los familiares que ya tienen ILA, estos tienen la proteína más alta". Es un paso más cerca de la enfermedad pero no es predicción longitudinal pura.

¿Por qué entonces es relevante para tu objetivo?

Porque la población es de altísimo riesgo. Los familiares de primer grado tienen entre 3 y 5 veces más probabilidad de desarrollar FPI que la población general. Si una proteína discrimina perfectamente entre los que ya tienen ILA y los que no dentro de ese grupo de alto riesgo, es muy probable que también esté elevada antes de que aparezca la ILA. Es el proxy más cercano a predicción precoz que existe en esta población específica.

Los números del recuadro superior

237 familiares. Es una muestra pequeña comparada con el UK Biobank. Eso tiene consecuencias: los OR pueden ser más inestables, los intervalos de confianza son más anchos. Pero es la única muestra de este tipo que existe, y además fue validada en una segunda cohorte independiente de Colorado.

26% con ILA. De los 237 familiares, 62 ya tenían ILA en el TAC. El 74% restante no tenía nada visible todavía. El estudio compara estos dos grupos.

7.596 aptámeros. SomaScan mide más del doble de proteínas que Olink. La ventaja es más cobertura. La desventaja es que algunas señales pueden ser menos específicas porque los aptámeros son menos selectivos que los anticuerpos de Olink.

AUC 0.89. El modelo simplificado de 3 proteínas más edad predice la presencia de ILA con un 89% de precisión en la cohorte de validación. Es muy bueno para una muestra de solo 237 personas.

Las proteínas: por qué estas y no otras

Aquí hay 7 proteínas significativas. Te explico cada una y por qué la priorizamos o no.

SFTPD — OR 4.16

Es la proteína con el OR más alto. Los familiares con ILA tenían SFTPD 4 veces más elevada que los sin ILA. SFTPD es una proteína surfactante, producida por las células alveolares tipo II del pulmón. Cuando el epitelio alveolar está dañado, libera más SFTPD a la sangre.

El problema es que SFTPD sube en cualquier daño pulmonar: EPOC, neumonía, asma, incluso infecciones respiratorias. No es específica de FPI. Por eso, aunque tiene el OR más alto, no es la proteína que más nos interesa para predicción específica de FPI. Es como un termómetro que sube con cualquier infección, no solo con una bacteria concreta.

La razón por la que aparece en el modelo LASSO simplificado (el de AUC 0.89) no es porque sea específica sino porque en esta población de familiares, donde el daño pulmonar que hay es mayoritariamente de origen fibrótico, su señal es útil. Pero en una población general sería mucho más ruidosa.

GDF15 — OR 4.08

Ya la conoces del estudio anterior donde tenía HR 1.92. Aquí tiene OR 4.08, el doble de efecto. Eso es interesante: en personas ya con ILA la señal es mucho más fuerte que en personas sanas de la población general.

¿Qué significa eso para tu objetivo? Que GDF15 sube con la enfermedad progresivamente. Está algo elevada años antes (señal en el UK Biobank), pero sube mucho más cuando ya hay daño estructural visible (ILA). Es un marcador dinámico que refleja la progresión, no solo el riesgo basal.

Esto la hace útil para monitorización y para diagnóstico de ILA, pero menos ideal como único predictor pre-clínico. En combinación con otras sigue siendo valiosa.

SFTPB — OR 4.00

Mismo razonamiento que SFTPD. Proteína surfactante, señal alta, pero muy inespecífica. Además hay un matiz técnico importante: hay evidencia de que SFTPB medida en vesículas extracelulares (en lugar de en suero libre) sí es bastante más específica de FPI. Pero en este estudio se mide en plasma libre, así que hay que tomar el OR con cautela.

El modelo LASSO la selecciona porque en esta población concreta funciona, pero en un contexto clínico general sería problemática por los falsos positivos.

WFDC2 — OR 2.59 en descubrimiento, 3.50 en validación

Aquí hay algo importante que fijarte. En el grupo de descubrimiento el OR es 2.59, pero en la cohorte de validación de Colorado el OR sube a 3.50. Es decir, la señal es más fuerte en la segunda cohorte que en la primera.

Eso normalmente no pasa. Lo habitual es que los OR bajen un poco en la validación porque el grupo de descubrimiento siempre tiene algo de sobreajuste. Que suba significa dos cosas: primero, que la señal es muy robusta y no fue un hallazgo casual. Segundo, que posiblemente la cohorte de Colorado tiene características que hacen la señal especialmente clara (como mayor prevalencia de FPI familiar o menor tabaquismo).

Esta proteína ya la conoces como la más consistente de todas las plataformas. Aquí lo confirma una vez más.

GCHFR — OR 2.45, no replica

Esta es la única de las 7 que no pasa la validación. En el grupo de descubrimiento tiene OR 2.45 y es significativa. En Colorado el OR baja a 1.32 y deja de ser significativo ($p=0.4$).

Eso nos dice que probablemente fue un hallazgo casual en la muestra pequeña de Boston. Con 156 personas en el grupo de descubrimiento, es posible que algunos valores extremos inflaran el OR artificialmente. La descartamos.

SFN (estratifina) — OR 2.26, sube a 3.24 en validación

Como WFDC2, su señal sube en la validación. Es otra proteína que se confirma de forma sólida. SFN es un regulador del ciclo celular. Cuando las células basaloideas del epitelio pulmonar se transforman en ese estado aberrante que precede a la fibrosis, SFN aumenta su expresión.

Lo más interesante de SFN es su comportamiento con el tabaco. En no fumadores su OR es 4.2, muy alto. En fumadores baja a 1.5 y deja de ser estadísticamente significativo. Esto tiene dos lecturas. La negativa: en cohortes con muchos fumadores no funciona bien. La positiva: en no fumadores puede ser uno de los marcadores más potentes de todos, precisamente porque no está contaminado por el daño del tabaco.

CDCP1 — OR 2.14, sube a 3.03 en validación

Tercera proteína que sube en la validación. Y la más interesante de las tres por un motivo que va más allá del número.

CDCP1 no es solo un marcador. Es una proteína transmembrana que activamente potencia la activación de TGF- β en los fibroblastos intersticiales. TGF- β es la señal central de la fibrosis: cuando se activa, los fibroblastos se convierten en miofibroblastos y producen colágeno en exceso. CDCP1 es como el acelerador de ese proceso.

Eso significa que CDCP1 elevada no solo indica que algo está pasando, sino que está participando en que pase. Es un marcador con mecanismo causal directo.

Además tiene una interacción importante con la edad. En menores de 60 años su OR es 2.9. En mayores de 60 es 1.9. Eso es contra-intuitivo porque la FPI es más frecuente en mayores. Lo que puede estar indicando es que en jóvenes, cuando CDCP1 está elevada, es una señal más específica de proceso fibrótico activo, mientras que en mayores puede subir también por otros procesos del envejecimiento. Si tu cohorte incluye personas relativamente jóvenes, CDCP1 es especialmente relevante.

La matriz de correlaciones: qué te dice en la práctica

El único número que destaca es el $R^2=0.78$ entre GDF15 y WFDC2. Todo lo demás está entre 0.31 y 0.63, que son correlaciones moderadas.

Lo que esto significa para un panel de biomarcadores es concreto. Si mides GDF15 y WFDC2 juntas, la segunda te añade poca información nueva sobre la primera. Pero si mides WFDC2 más CDCP1 (correlación 0.57) o WFDC2 más SFN (correlación 0.55), cada proteína te da información que la otra no tenía.

El panel más eficiente de información no redundante sería **WFDC2 + CDCP1 + SFN**, porque capturan tres procesos biológicos distintos: daño epitelial (WFDC2), activación de fibroblastos (CDCP1) y transformación de células basaloideas (SFN).

El modelo simplificado LASSO: qué significa ese AUC 0.89

El algoritmo LASSO seleccionó automáticamente las variables más útiles para predecir ILA, descartando las redundantes. Eligió GDF15, SFTPD, SFTPB y la edad.

Eso puede sorprenderte porque WFDC2, CDCP1 y SFN tienen señales más interesantes mecanísticamente. La razón por la que LASSO no las eligió es matemática: GDF15 y WFDC2 están muy correlacionadas, así que el algoritmo solo necesita una de las dos. Eligió GDF15. SFTPD y SFTPB tienen OR muy altos en esta población concreta aunque sean inespecíficas, y eso hace que el algoritmo las prefiera para maximizar el AUC en esta muestra.

No significa que WFDC2 o CDCP1 sean peores para tu objetivo real de predicción de FPI. Significa que para clasificar ILA vs sin ILA en esta muestra específica de familiares, el algoritmo encontró esa combinación óptima.

El resultado práctico es notable: con solo 3 proteínas y la edad, si aplicas el umbral de máxima sensibilidad, podrías evitar el TAC en 1 de cada 2.2 personas cribadas sin perder ningún caso. En una población de familiares donde el TAC tiene radiación y coste, eso tiene valor clínico real.

La conclusión práctica de esta pestaña

Esta segunda pestaña añade lo que el UK Biobank no tenía: datos en una población de altísimo riesgo real (familiares directos de pacientes con FPI) y con una plataforma que mide el doble de proteínas.

Las proteínas que salen reforzadas después de leer esta pestaña son **WFDC2** (confirmada de nuevo), **CDCP1** (mecanismo causal + señal más fuerte en jóvenes) y **SFN** (la más potente en no fumadores). GCHFR queda descartada. SFTPB y SFTPD son útiles en este contexto pero hay que tomarlas con cautela por su inespecificidad.

Pestaña 3: SomaScan / QIA precursor

El estudio en una frase

Cogieron más de 7.000 personas de dos cohortes completamente distintas, midieron proteínas en sangre con SomaScan, y las cruzaron con una medida automática por ordenador de anomalías pulmonares microscópicas en el TAC, llamadas QIA, que son anteriores incluso a lo que el ojo humano detecta como ILA.

Qué son las QIA y por qué importan para tu objetivo

Este es el concepto más nuevo de los tres estudios y el más relevante si buscas predicción verdaderamente precoz.

En el estudio anterior (ILA familiar) mirábamos si el radiólogo veía anomalías en el pulmón. En este estudio un algoritmo de machine learning analiza el TAC pixel a pixel y detecta cambios sutilísimos en la densidad del tejido pulmonar que el ojo humano no vería. A eso lo llaman QIA, anomalías intersticiales cuantitativas.

La jerarquía temporal de la enfermedad quedaría así, de más precoz a más tardío:

QIA (cambios microscópicos, solo detectables por algoritmo) → **ILA** (anomalías visibles para el radiólogo) → **FPI diagnosticada** (enfermedad clínica establecida)

Si una proteína predice QIA, está señalando el proceso fibrótico en su estadio más embrionario posible. Por eso este estudio es tan valioso para tu objetivo aunque sea transversal como el anterior.

Las dos cohortes y por qué importa que sean tan distintas

COPDGene: 4.383 personas. Edad media 65 años. Todos son fumadores o exfumadores con al menos 10 años de tabaco. Mucha enfermedad pulmonar de fondo. Es una población donde el daño pulmonar es frecuente y variado.

CARDIA: 2.925 personas. Edad media 50 años. El 51% nunca ha fumado. Población más joven y más sana. Es una cohorte de seguimiento cardiovascular que no tenía nada que ver con pulmón originalmente.

La razón por la que usar estas dos cohortes juntas es muy inteligente: si una proteína predice QIA tanto en fumadores mayores con daño pulmonar de fondo como en jóvenes sanos sin historial de tabaco, esa señal es genuinamente robusta y no está contaminada por el tabaco o la edad.

Y el resultado es llamativo: la correlación entre los efectos de las proteínas en COPDGene y en CARDIA es $r=0.92$. Prácticamente idéntica. Las mismas proteínas suben en el mismo orden en ambas poblaciones.

Qué mide el beta (β) en este estudio

En los estudios anteriores tenías HR y OR. Aquí el número es diferente y merece explicación propia.

El β te dice cuánto cambia el porcentaje de QIA en el pulmón por cada unidad logarítmica de incremento en la proteína. Es decir, si WFDC2 sube una unidad en su escala logarítmica, el porcentaje de pulmón afectado por QIA aumenta 2.74 puntos porcentuales.

No es un riesgo relativo como el HR o el OR. Es un efecto cuantitativo directo sobre cuánto tejido pulmonar está afectado. Un β de 2.87 (el de LUM) significa que por cada unidad que sube esa proteína, casi un 3% más del pulmón muestra cambios microscópicos de fibrosis.

Las proteínas positivas: por qué estas y no otras

LUM (Lumican) — β +2.87 en COPDGene, +2.56 en CARDIA

Es la proteína con el efecto más alto de todo el estudio y además es la más consistente entre las dos cohortes: casi el mismo número en fumadores mayores y en jóvenes sanos.

LUM es un proteoglicano de la matriz extracelular. En lenguaje llano: es una proteína estructural del andamiaje entre células. Cuando el tejido pulmonar empieza a remodelarse hacia fibrosis, LUM se libera a la sangre. Es una señal de que la arquitectura del pulmón está cambiando.

Lo llamativo es que LUM no aparecía en las pestañas anteriores. No está en el Olink del UK Biobank ni en el estudio de familiares con las mismas proteínas. ¿Por qué? Porque SomaScan mide más proteínas que Olink. LUM estaba ahí, pero Olink no la mide. Esto es un ejemplo claro de por qué la cobertura de la plataforma importa.

LUM es la proteína más prometedora para explorar en estudios futuros precisamente porque tiene la señal más fuerte en el estadio más precoz (QIA) y no estaba en el radar antes.

WFDC2 — β +2.74 en COPDGene, +1.96 en CARDIA

De nuevo. Tercera pestaña, tercera vez que aparece WFDC2 con señal significativa. Ya no hay duda de que esta proteína refleja algo real en el proceso fibrótico. En este contexto su señal es algo menor en CARDIA que en COPDGene, lo que tiene sentido porque los fumadores mayores tienen más QIA de base.

CXCL16 — β +2.62 en COPDGene, +2.58 en CARDIA

Esta es la proteína más consistente entre las dos cohortes de todas las positivas. Prácticamente el mismo efecto en fumadores de 65 años y en jóvenes de 50. CXCL16 es una quimiocina que recluta células inmunes al pulmón. Su señal tan consistente sugiere que

el proceso inflamatorio que precede a la fibrosis no depende del tabaco ni de la edad sino de algo más fundamental.

No aparece en las pestañas anteriores con tanta fuerza, pero aquí destaca. Es una candidata interesante para explorar como marcador de inflamación pre-fibrótica.

CCL18 — β +2.06 en COPDGene, +0.99 en CARDIA

CCL18 es una quimiocina clásica de la FPI, ya conocida como marcador de actividad en la enfermedad establecida. Aquí aparece con señal fuerte en COPDGene pero débil en CARDIA. Eso te dice algo importante: CCL18 sube en QIA en fumadores con daño pulmonar de fondo, pero en gente joven sana su señal es mucho menor.

Eso sugiere que CCL18 está más relacionada con el daño crónico por tabaco que con el proceso fibrótico específico. Para tu objetivo de predicción específica de FPI, no es la proteína más útil.

B2M (Beta-2-microglobulina) — β +1.97 en COPDGene, +1.78 en CARDIA

B2M es una proteína del complejo mayor de histocompatibilidad, relacionada con el envejecimiento celular. Cuando las células envejecen y entran en senescencia, liberan más B2M. En el contexto de FPI, la senescencia del epitelio alveolar es uno de los mecanismos que se cree desencadena la fibrosis.

Lo interesante de B2M es que su señal es bastante consistente entre las dos cohortes (1.97 vs 1.78), lo que sugiere que refleja un proceso de envejecimiento celular independiente del tabaco. Es una proteína que conecta FPI con biología del envejecimiento, un área de investigación muy activa.

CDCP1 — β +1.78 en COPDGene, +1.64 en CARDIA

Segunda vez que aparece CDCP1 en dos pestañas distintas. Aquí confirma que su señal no solo existe en familiares de alto riesgo sino también en la población general con QIA. Y de nuevo, la señal es consistente entre fumadores y no fumadores.

La razón por la que la destacamos aquí igual que en la pestaña anterior es su mecanismo causal. CDCP1 no solo sube cuando hay daño, sino que activamente amplifica ese daño activando TGF- β . Ver esta proteína elevada en el estadio de QIA, que es el más precoz posible, refuerza la hipótesis de que CDCP1 participa en el inicio del proceso fibrótico, no solo en su progresión.

GDF15 — β +1.61 en COPDGene, +0.84 en CARDIA

Aparece de nuevo pero con una diferencia llamativa entre las dos cohortes: casi el doble de efecto en fumadores mayores que en jóvenes sanos. Eso confirma lo que ya intuíamos: GDF15 está parcialmente confundida con el daño por tabaco y el envejecimiento. En jóvenes no fumadores su señal es mucho más débil.

Las proteínas protectoras: las que bajan cuando hay más QIA

EGFR — β -4.35 en COPDGene, -3.40 en CARDIA

Aquí está la confirmación definitiva de EGFR como protector. El efecto más grande de todo el estudio, en ambas cohortes, en fumadores y no fumadores. Y recuerda que en el Olink del UK Biobank también era el protector más fuerte (HR 0.67).

Tres datasets distintos, dos plataformas distintas, el mismo mensaje: cuando EGFR está bajo en sangre, el pulmón tiene más daño microscópico. Cuando está alto, el pulmón está más protegido.

La explicación biológica es que EGFR regula la capacidad del epitelio pulmonar de repararse tras un daño. Cuando EGFR funciona bien, el pulmón se repara correctamente. Cuando falla, responde con fibrosis en lugar de regeneración.

NPS (Neuropéptido S) — β -3.28 en COPDGene, -2.68 en CARDIA

El segundo protector más fuerte. NPS es un neuropéptido con función antiinflamatoria en el pulmón. Cuando NPS baja, la inflamación que precede a la fibrosis tiene menos freno. Su señal consistente entre las dos cohortes es llamativa, aunque no aparece en los otros estudios y necesitaría validación adicional.

APOM (Apolipoproteína M) — β -2.85 en COPDGene, -1.49 en CARDIA

APOM es una proteína transportadora de lípidos. Su papel en FPI no está claro, pero su asociación inversa con QIA aparece de forma consistente. Podría estar reflejando un estado metabólico que protege contra la fibrosis, pero es especulativo por ahora.

El hallazgo más importante de esta pestaña para tu objetivo

La correlación $r=0.92$ entre COPDGene y CARDIA es el resultado más sólido de todo el estudio.

Lo que significa en la práctica es que las mismas proteínas, con efectos de magnitud similar, predicen daño pulmonar microscópico tanto en personas de 65 años con décadas de tabaco como en personas de 50 años que nunca han fumado. Eso descarta que las señales sean artefactos del tabaco o del envejecimiento.

Además, hay 49 proteínas que son significativas incluso restringiendo el análisis solo a los nunca fumadores de CARDIA. Eso es especialmente relevante si tu cohorte incluye personas sin tabaquismo, porque confirma que estas proteínas capturan procesos fibróticos independientes del humo del cigarrillo.

La conclusión práctica de esta pestaña

Esta tercera pestaña añade dos cosas que las anteriores no tenían.

Primero, el estadio más precoz posible de la enfermedad. Las QIA son anteriores a la ILA, que ya era anterior a la FPI clínica. Si buscas el marcador más temprano, lo más cercano que tenemos hoy son las proteínas que predicen QIA.

Segundo, una proteína nueva que no había aparecido antes: **LUM (Lumican)**. Con el β más alto de todo el estudio y consistente entre las dos cohortes, es una hipótesis abierta y muy prometedora para investigación futura.

Las proteínas que salen reforzadas de esta pestaña son **WFDC2** (confirmada por tercera vez), **CDCP1** (confirmada por segunda vez con mecanismo causal), **EGFR** como protector (confirmado por tercera vez) y **LUM** como novedad relevante. CXCL16 también es interesante como marcador de inflamación pre-fibrótica consistente entre poblaciones.

Pestaña 4: Comparativa cruzada

Para qué sirve esta pestaña

Las tres pestañas anteriores te daban cada estudio por separado. Esta pestaña responde a la pregunta más importante de todas: **¿qué proteínas tienen señal en más de un estudio?**

Porque una proteína que sale en un solo estudio puede ser casualidad. Una proteína que sale en dos estudios distintos, con plataformas distintas, en poblaciones distintas, ya es difícil de ignorar. Y una que sale en tres es prácticamente imposible que sea un hallazgo aleatorio.

La tabla central: cómo leerla

La tabla tiene tres columnas de números: el HR del Olink (longitudinal, personas sanas), el OR del SomaScan de familiares (ILA en alto riesgo) y el β del SomaScan de QIA (daño microscópico pre-ILA).

Cada columna representa un estadio diferente de la enfermedad, de izquierda a derecha desde el más precoz al más tardío. Y cada fila te dice si esa proteína tiene señal en ese estadio.

Las proteínas con señal en más de un estudio

WFDC2 — aparece en los tres

HR 2.06 en Olink (personas sanas, 13 años antes), OR 2.59 en SomaScan familiares (ILA establecida) y β +2.74 en SomaScan QIA (daño microscópico previo a ILA).

Tiene señal en el estadio más precoz posible, en el estadio intermedio y en predicción longitudinal pura. No hay otra proteína en toda la literatura de FPI que tenga esa trifecta. Es la proteína más robusta de todas las que hemos visto.

Lo que esto confirma es que WFDC2 no sube de golpe cuando aparece la FPI. Va subiendo progresivamente desde el estadio de QIA, se mantiene elevada en ILA y sigue elevada cuando ya hay FPI clínica. Eso es exactamente el comportamiento ideal de un biomarcador de predicción precoz.

GDF15 — aparece en los tres pero con matiz importante

HR 1.92 en Olink, OR 4.08 en familiares y β +1.61 en QIA. Está en los tres estudios, pero si te fijas en los números hay algo revelador. En el UK Biobank (personas sanas) tiene HR 1.92. En familiares con ILA tiene OR 4.08, el doble de efecto. Eso significa que GDF15 sube mucho más cuando ya hay enfermedad establecida que cuando aún no hay nada.

En términos prácticos: GDF15 sube algo antes de la enfermedad pero sube mucho más con ella. Es un marcador que te dice que algo está pasando, pero es más útil para confirmar progresión que para predecir inicio. No es el marcador más específico de la fase pre-clínica que buscas.

CDCP1 — aparece en dos estudios

OR 2.14 en familiares con ILA y β +1.78 en QIA poblacional. No está en el Olink del UK Biobank porque ese estudio no la analizó dentro de sus paneles principales, no porque su señal no exista. Y en los dos estudios donde aparece, su señal es consistente en fumadores, no fumadores, mayores y jóvenes.

Lo que distingue a CDCP1 del resto es que no es un marcador pasivo. Activamente acelera la fibrosis activando TGF- β en los fibroblastos. Tener CDCP1 elevada en el estadio de QIA significa que el pulmón no solo está dañado sino que está activamente acelerando ese daño. Es una señal de alarma más específica que una proteína que simplemente refleja inflamación genérica.

EGFR — aparece como protector en dos estudios

HR 0.67 en Olink y β -4.35 en SomaScan QIA. El efecto protector más robusto de todos. En el Olink es el protector más fuerte de los 34 que encontraron. En SomaScan QIA es el negativo más grande de todos los negativos, con mucha diferencia.

Lo que esto significa en la práctica es que EGFR bajo en sangre es una señal de riesgo tan consistente como WFDC2 alta. Si mides ambas y WFDC2 está alta y EGFR está baja al mismo tiempo, esa combinación debería ser una señal de alarma muy seria.

Las proteínas que solo aparecen en un estudio y qué significa eso

LAMP3, SPINT1 y CEACAM6 — solo en Olink

Estas tres solo aparecen en el UK Biobank, el estudio longitudinal. No están en los estudios de SomaScan porque Olink y SomaScan no miden exactamente las mismas proteínas. Olink tiene paneles específicos y estas tres están en sus paneles de oncología, neurología e inflamación respectivamente.

Que no aparezcan en SomaScan no significa que su señal sea falsa. Significa que no han sido testadas en esos otros contextos todavía. Son las proteínas con más potencial para investigación futura precisamente porque tienen señal longitudinal en el estudio más grande y riguroso, pero nadie ha podido confirmarlas aún en poblaciones de alto riesgo o en estadios pre-ILA. Hay un hueco de conocimiento ahí que es una oportunidad.

LUM — solo en SomaScan QIA

LUM apareció en la tercera pestaña como la proteína con el β más alto de todo el estudio de QIA. Y sin embargo no aparece en el UK Biobank ni en el estudio de familiares. Exactamente la situación inversa a LAMP3.

La razón más probable es que Olink no la mide en sus paneles actuales. Lo cual significa que una proteína potencialmente muy importante para la predicción más precoz de FPI está siendo ignorada simplemente por limitaciones de cobertura de la plataforma más usada.

SFN y SFTPB — solo en SomaScan familiares

SFN tiene OR 2.26 en familiares pero no aparece en QIA ni en el Olink. Su señal puede ser real pero limitada a poblaciones de altísimo riesgo genético como los familiares directos. En población general su señal puede ser demasiado débil para detectarla.

SFTPB tiene OR alto pero como ya discutimos es demasiado inespecífica para ser útil como biomarcador predictivo de FPI específicamente.

La comparativa de plataformas en términos prácticos

Olink y SomaScan no son intercambiables. Miden cosas solapadas pero no idénticas, con tecnologías distintas.

Olink usa anticuerpos, que son muy selectivos. Si un anticuerpo dice que hay WFDC2, casi seguro que hay WFDC2. La desventaja es que solo mide lo que tiene anticuerpos, y hay proteínas que simplemente no están en sus paneles.

SomaScan usa aptámeros de DNA que se unen a las proteínas por afinidad química. Es más parecido a una red de pesca: captura más cosas pero algunas pueden ser capturas accidentales. La ventaja es una cobertura enormemente mayor.

Para tu objetivo de investigación, lo ideal sería usar ambas. Pero si tienes que elegir una, la recomendación depende de qué quieras responder. Si quieres predecir FPI en población general con el máximo rigor estadístico, Olink. Si quieres descubrir proteínas nuevas en una población de alto riesgo donde cubrir todo el proteoma importa, SomaScan.

La conclusión más importante de esta pestaña

Al cruzar los tres estudios emergen cuatro proteínas que nadie debería ignorar si diseña un panel para predicción de FPI.

WFDC2 porque aparece en todos los estudios, en todas las plataformas, en todas las poblaciones. Es el biomarcador más robusto de la fibrosis pulmonar pre-clínica que existe hoy.

CDCP1 porque aparece en dos estudios con mecanismo causal directo y señal consistente independientemente del tabaco y la edad.

EGFR porque su señal protectora es la más consistente y grande de todos los marcadores negativos en dos plataformas distintas. Un EGFR bajo en sangre es tan informativo como un WFDC2 alto.

LAMP3 porque en el único estudio que la mide longitudinalmente tiene el HR más alto de todos, y nadie ha podido confirmarla todavía en los otros contextos. Es la proteína con más potencial inexplorado.

Pestaña 5: Variables demográficas

Para qué sirve esta pestaña

Las cuatro pestañas anteriores te explicaban qué proteínas son relevantes. Esta pestaña responde a algo diferente: **¿cambia la señal de esas proteínas dependiendo de quién seas?**

Edad, sexo, tabaco e IMC no son solo covariables que hay que ajustar estadísticamente. Son modificadores reales del efecto. Algunas proteínas funcionan mejor en jóvenes que en mayores. Otras solo funcionan en no fumadores. Entender eso es fundamental para diseñar bien un panel predictivo.

La conclusión más importante antes de empezar

Las variables demográficas importan, pero no reemplazan a las proteínas. Ese es el mensaje central de esta pestaña.

Con solo saber la edad, el sexo, si fuma y el IMC de una persona, predices quién desarrollará FPI con un acierto del 77.9%. Eso ya es útil. Pero añadir las proteínas sube ese acierto al 88.4% en el modelo honesto, o al 98.6% en el optimista. Las proteínas multiplican la capacidad predictiva de cualquier modelo clínico.

Dicho de otra manera: si solo usas variables clínicas, de cada 10 personas de alto riesgo que identificas, 2 o 3 las clasificas mal. Con proteínas, ese error baja drásticamente.

Qué variables demográficas predicen FPI por sí solas

Estas son las que componen el modelo base del UK Biobank, el que da C-index 0.779 sin ninguna proteína.

Edad es el predictor más fuerte de todos. La FPI es una enfermedad que casi no existe en menores de 50 años y su frecuencia aumenta progresivamente con la edad. Cuanto mayor es una persona, más tiempo ha tenido el pulmón para acumular daño y más probabilidad hay de que ese daño derive en fibrosis.

Sexo masculino aumenta el riesgo. Los hombres desarrollan FPI con más frecuencia que las mujeres. La razón no está completamente aclarada pero puede estar relacionada con diferencias en la respuesta inmune y en la exposición laboral histórica a polvo y fibras.

Tabaco en cantidad. No es igual fumar 5 cigarrillos al día que dos paquetes. En el modelo se distingue entre nunca fumador, exfumador, fumador actual leve (menos de 20 paquetes-año) y fumador intenso (más de 20 paquetes-año). A más exposición acumulada, más riesgo.

IMC alto aumenta el riesgo. Probablemente porque el exceso de peso ejerce presión mecánica sobre el pulmón y porque la obesidad genera inflamación sistémica crónica que puede acelerar el daño pulmonar.

Tabaco pasivo añade riesgo adicional independiente del tabaco propio. Esto sugiere que la exposición al humo tiene un efecto sobre el pulmón que no es dosis-dependiente de forma lineal.

Nivel socioeconómico bajo se asocia a mayor riesgo. Esto puede reflejar mayor exposición laboral a polvos y fibras, peor acceso a atención médica temprana, y posiblemente mayor estrés crónico.

Actividad física adecuada y dieta sana son protectoras. No de forma dramática, pero su efecto es real y consistente en el modelo.

Cómo modifican las variables demográficas la señal de cada proteína

Aquí es donde esta pestaña se vuelve verdaderamente útil para el diseño de tu estudio.

CDCP1 interacciona con la edad

La interacción entre CDCP1 y la edad tiene un p-valor de 0.04, que es estadísticamente significativo. Lo que eso significa en números concretos es que en personas menores de 60 años, el OR de CDCP1 para predecir ILA es 2.9. En personas de 60 o más, baja a 1.9.

Esto es contra-intuitivo a primera vista porque la FPI es más frecuente en mayores. Pero tiene una explicación biológica plausible. En personas jóvenes, que CDCP1 esté elevada es una señal más específica de proceso fibrótico activo porque no hay tantos otros procesos que la eleven. En mayores, CDCP1 puede subir también por envejecimiento normal, inflamación crónica de otras causas, o comorbilidades frecuentes en esa edad. La señal se vuelve más ruidosa.

La consecuencia práctica para tu diseño es clara: si tu cohorte incluye personas relativamente jóvenes, CDCP1 es especialmente valiosa. Si es una cohorte de mayores de 65, su señal será más débil y deberás complementarla con otras proteínas.

SFN interacciona con el tabaco

La interacción entre SFN y el tabaco tiene un p-valor de 0.05, en el límite de la significación. En no fumadores el OR de SFN para predecir ILA es 4.2, muy alto. En fumadores baja a 1.5 y deja de ser estadísticamente significativo.

Hay dos formas de interpretar esto. La negativa es que SFN no funciona bien en cohortes con fumadores. La positiva es que en no fumadores es uno de los marcadores más potentes de todos, precisamente porque cuando SFN está elevada en alguien sin tabaco, no puede explicarse por daño de humo y muy probablemente refleja proceso fibrótico específico.

Si tu cohorte tiene muchos fumadores, SFN no es tu proteína. Si tiene muchos no fumadores, SFN puede ser una de las más útiles.

WFDC2, GDF15, SFTPB y SFTPD no interaccionan con nada

Sus p-valores de interacción con edad, sexo y tabaco son todos mayores de 0.1. Eso significa que funcionan igual de bien en jóvenes y mayores, en hombres y mujeres, en fumadores y no fumadores. Son proteínas universales en el sentido de que su señal no depende de quién seas.

Esto es una ventaja enorme para cualquier panel que quieras diseñar, porque puedes aplicarlo a cualquier tipo de población sin tener que estratificar.

Los subgrupos con señal proteómica más fuerte

El estudio del UK Biobank analizó los subgrupos por separado y encontró que hay una combinación de características donde las proteínas predicen FPI con especial fuerza.

Hombres mayores de 60 años exfumadores es el subgrupo donde más proteínas son significativas y donde los HR son más altos. No es sorprendente porque es exactamente el perfil típico del paciente con FPI. Lo que sí es interesante es que dentro de ese subgrupo, dos proteínas protectoras, ENPP6 e IGFBP3, solo son significativas aquí y no en otros subgrupos.

ENPP6 es una enzima que regula el metabolismo de los lípidos en el pulmón. Su señal protectora solo aparece en hombres mayores fumadores, lo que sugiere que su mecanismo está relacionado con el daño lipídico acumulado por el tabaco. En otros perfiles demográficos no tiene valor predictivo.

IGFBP3 regula la señalización del factor de crecimiento insulínico. Su papel protector en FPI podría estar relacionado con la regulación de la proliferación de fibroblastos, pero al igual que ENPP6 solo funciona en ese subgrupo específico. Si tu cohorte es mixta o incluye mujeres y jóvenes, estas dos proteínas no te sirven.

La limitación más importante de esta pestaña

Casi todos los datos vienen de población de ancestría europea. El UK Biobank es mayoritariamente blanco británico. Los estudios de familiares son mayoritariamente blancos americanos.

Eso importa porque ya sabemos que algunos genes de riesgo de FPI, como PSKH1, solo son detectables en población asiática. Es posible que algunos biomarcadores proteicos también tengan patrones diferentes según la ancestría. Hoy no tenemos datos para saberlo, lo que significa que cualquier panel diseñado con estos datos debería validarse específicamente antes de aplicarlo a poblaciones de otras ancestrías.

Cómo usar esta pestaña para diseñar tu panel

Si tuvieras que extraer una guía práctica de todo lo que dice esta pestaña, sería esta.

Empieza siempre con **WFDC2 y GDF15** porque funcionan en todos los subgrupos sin excepción y tienen señal en todos los estadios de la enfermedad.

Añade **CDCP1** si tu población incluye personas menores de 60 años. Añade **SFN** si tu población tiene muchos no fumadores. Descarta o trata con cautela SFN en cohortes con fumadores.

Considera **EGFR como marcador protector** complementario porque su señal es independiente de la demografía y muy consistente entre plataformas.

Si tu población es específicamente hombres mayores exfumadores, ENPP6 e IGFBP3 pueden añadir valor adicional. En cualquier otra combinación demográfica, no las incluirías.

Y recuerda que ninguna de estas proteínas, ni siquiera WFDC2, te da la respuesta sola. El valor real está en combinarlas porque cada una captura un proceso biológico distinto: daño epitelial, activación de fibroblastos, inflamación pre-fibrótica, y capacidad de reparación pulmonar.

La conclusión final de las cinco pestañas juntas

Ahora que has visto todo, la imagen completa es esta.

Hay un núcleo de proteínas que tienen señal demostrada antes de que la FPI aparezca, en múltiples estudios, con múltiples plataformas y en múltiples tipos de población. Ese núcleo es **WFDC2, CDCP1, EGFR y LAMP3**. Si hubieras de diseñar un panel mínimo y robusto para predecir FPI antes de que exista, empezarías por ahí.

Alrededor de ese núcleo hay proteínas que añaden valor en contextos específicos: GDF15 para monitorizar progresión, SFN en no fumadores, LUM como hipótesis nueva en estadios muy precoces, y CCL21/CXCL9 como marcadores del proceso inflamatorio que conecta todo.

Y hay un marcador protector que merece tanta atención como los de riesgo: EGFR bajo en sangre es una señal de alarma tan importante como WFDC2 alta, y se confirma en tres estudios distintos.

1. Olink / UK Biobank

Zhou R et al. *Large scale plasma proteomic profiles improve prediction of idiopathic pulmonary fibrosis in general population*. Respiratory Research, 2025.

<https://link.springer.com/article/10.1186/s12931-025-03418-z>

2. SomaScan / ILA familiar

Rose JA et al. *Protein biomarkers of interstitial lung abnormalities in relatives of patients with pulmonary fibrosis*. European Respiratory Journal, 2025.

<https://publications.ersnet.org/content/erj/65/6/2401349>

3. SomaScan / QIA precursor

Choi B et al. *Proteomic biomarkers of quantitative interstitial abnormalities in COPD Gene and CARDIA Lung Study*. American Journal of Respiratory and Critical Care Medicine, 2024.

<https://pmc.ncbi.nlm.nih.gov/articles/PMC11092953/>